

# 学习笔记

---

## 正则化

下午6:21 4月2日周四

64%

< 物理

算法笔记

> 草稿

算法笔记

常见的向量范数:


$L_0$  范数:  $\|x\|_0$  表示向量  $x$  中非零元素的个数

$L_1$  范数:  $\|x\|_1 = \sum_{i=1}^n |x_i|$  表示非零元素的绝对值之和

$L_2$  范数:  $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$

$L_p$  范数:  $\|x\|_p = \sqrt[p]{\sum_{i=1}^n x_i^p}$

过拟合:



红: 恰好,  $y = w_0 + w_1 x_1$

绿: 过拟合,  $y = w_0 + w_1 x_1 + w_2 x_2 + \dots$

如何令  $y = w_0 + w_1 x_1 \rightarrow y = w_0 + w_1 x_1 + w_2 x_2 + \dots$  呢?

减少向量  $w$  的个数 or 令某些参数减小  $\rightarrow$  正则化

推理: 损失函数  $J(w, x, y)$

减小某些  $w$  的值, 但又不知道该减少哪一个  $w$ , 因此可以设限制条件

$$\textcircled{1} \begin{cases} |w_1| + |w_2| + |w_3| + \dots + |w_n| = \|w\|_1 \leq L \\ \arg\min J(w, x, y) \end{cases} \quad \textcircled{2} \begin{cases} \sqrt{w_1^2 + w_2^2 + w_3^2 + \dots + w_n^2} = \|w\|_2 \leq L \\ \arg\min J(w, x, y) \end{cases}$$

先研究  $\textcircled{1}$ : 引入拉格朗日函数, 可得

$$L(w) = J(w, x, y) + \lambda (\|w\|_1 - L)$$

$\uparrow$   
min

要令  $L(w)$  最小, 则令  $\frac{\partial L(w)}{\partial \lambda} = 0$ , 设其解为  $\lambda^*$

下午6:21 4月2日周四

算法笔记

物理 草稿 算法笔记

$$\begin{aligned}
 \text{则} \min L(w, \lambda) &= \min J(w, x, y) + \lambda^* (\|w\|_1 + C) \\
 &= \min J(w, x, y) + \lambda^* \|w\|_1 + \lambda^* C \\
 &\propto \min J(w, x, y) + \lambda^* \|w\|_1
 \end{aligned}$$

$L_1$  正则化

$\therefore$  损失函数:  $J(w, x, y) + \lambda \|w\|_1$

$= J(w, x, y) + \lambda \sum_{i=1}^n |w_i|$

$L_2$  正则化同理

几何解释:

● :  $w_1$  与  $w_2$  的取值范围     ● : 损失函数最小的点  
● :  $w_1$  与  $w_2$  取值范围内与 ● 最近的点, 也是  $w_1$  与  $w_2$  取值点

下午6:15 4月2日周四

66%

< 品 Q ㉟ ㉟

算法笔记

↶ ↷ ㉟ ✕ ...

× 物理

× 草稿

× 算法笔记

㉟




## 线性判别分析:

思想: 如图所示, 要找出一条线, 使样本点  
映射后易于区分(类内小, 类间大)

$$X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{bmatrix}_{n \times p} \quad (x_i \text{ 均为列向量})$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}_{n \times 1}$$



推导: 映射后的值:  $z_i = w^T x_i$ , 均值:  $\bar{z} = \frac{1}{N} \sum_{i=1}^N z_i = \frac{1}{N} \sum_{i=1}^N w^T x_i$

映射后的方差:  $s = \frac{1}{N} \sum_{i=1}^N (z_i - \bar{z})^2 = \frac{1}{N} \sum_{i=1}^N (z_i - \bar{z})(z_i - \bar{z})^T$

$$\text{则类1: } \begin{cases} \bar{z}_1 = \frac{1}{N_1} \sum_{i=1}^{N_1} w^T x_i \\ s_1 = \frac{1}{N_1} \sum_{i=1}^{N_1} (z_i - \bar{z}_1)(z_i - \bar{z}_1)^T \end{cases}, \text{类2: } \begin{cases} \bar{z}_2 = \frac{1}{N_2} \sum_{i=1}^{N_2} w^T x_i \\ s_2 = \frac{1}{N_2} \sum_{i=1}^{N_2} (z_i - \bar{z}_2)(z_i - \bar{z}_2)^T \end{cases}$$

类间:  $(\bar{z}_1 - \bar{z}_2)^2$ , 类内:  $s_1 + s_2$ , 目标: 类内小, 类间大  $\rightarrow$  loss 函数

$$\text{loss 函数: } J(w) = \frac{(\bar{z}_1 - \bar{z}_2)^2}{s_1 + s_2}, \quad \text{目标: } \arg\max(J(w))$$

$$J(w): \text{分子} = \left( \frac{1}{N_1} \sum_{i=1}^{N_1} w^T x_i - \frac{1}{N_2} \sum_{i=1}^{N_2} w^T x_i \right)^2 = \left[ w^T \left( \frac{1}{N_1} \sum_{i=1}^{N_1} x_i - \frac{1}{N_2} \sum_{i=1}^{N_2} x_i \right) \right]^2 = \left[ w^T (\bar{x}_{c1} - \bar{x}_{c2}) \right]^2$$

$$\text{分母以 } s_1 \text{ 为例: } s_1 = \frac{1}{N_1} \sum_{i=1}^{N_1} (w^T x_i - \frac{1}{N_1} \sum_{j=1}^{N_1} w^T x_j) (w^T x_i - \frac{1}{N_1} \sum_{j=1}^{N_1} w^T x_j)^T \quad \text{把 } w^T \text{ 提出来}$$

$$= \frac{1}{N_1} \sum_{i=1}^{N_1} w^T (x_i - \bar{x}_{c1}) (x_i - \bar{x}_{c1})^T w = w^T \left[ \frac{1}{N_1} \sum_{i=1}^{N_1} (x_i - \bar{x}_{c1}) (x_i - \bar{x}_{c1})^T \right] w = w^T S_{c1} w$$

$$\therefore \text{分母} = w^T S_{c1} w + w^T S_{c2} w = w^T (S_{c1} + S_{c2}) w$$

$$\therefore J(w) = \frac{w^T (\bar{x}_{c1} - \bar{x}_{c2}) (\bar{x}_{c1} - \bar{x}_{c2})^T w}{w^T (S_{c1} + S_{c2}) w}$$

下午 6:15 4月2日周四

66%

< 物理

算法笔记

返回 草稿 算法笔记



$$\therefore J(w) = \frac{W^T (\bar{x}_{c1} - \bar{x}_{c2}) (\bar{x}_{c1} - \bar{x}_{c2})^T W}{W^T (S_{c1} + S_{c2}) W}, \quad \begin{aligned} \frac{1}{2} S_b &= (\bar{x}_{c1} - \bar{x}_{c2}) (\bar{x}_{c1} - \bar{x}_{c2})^T && \text{类间方差} \\ S_w &= (S_{c1} + S_{c2}) && \text{类内方差} \end{aligned}$$

$$R: J(w) = W^T S_b W \cdot (W^T S_w W)^{-1}$$

$$\frac{\partial J(w)}{\partial W} = 2 S_b W (W^T S_w W)^{-1} + W^T S_b W \cdot (-1) \cdot (W^T S_w W)^{-2} \cdot 2 S_w \cdot W = 0, \text{ 可得}$$

$$S_b W \cdot \underbrace{(W^T S_w W)^{-1}}_{\in R} = \underbrace{W^T S_b W}_{\in R} S_w^{-1} W \quad \begin{aligned} S_w: (p \times p) \quad S_b: (p \times p) \quad W: (n \times p) \quad W^T: (p \times n) \\ \text{求的是方向向量} \end{aligned}$$

$$S_w W = \frac{W^T S_w W}{W^T S_b W} S_b W \rightarrow W = \frac{W^T S_w W}{W^T S_b W} S_w^{-1} S_b W \propto S_w^{-1} S_b W$$

$$S_b W = (\bar{x}_{c1} - \bar{x}_{c2}) \underbrace{(\bar{x}_{c1} - \bar{x}_{c2})^T}_{p \times 1} \cdot \underbrace{W}_{1 \times p} \propto (\bar{x}_{c1} - \bar{x}_{c2})$$

$$\therefore W \propto S_w^{-1} (\bar{x}_{c1} - \bar{x}_{c2}) \quad \text{经验: } b = -\frac{1}{2} W^T (\bar{x}_{c1} - \bar{x}_{c2})$$

$$\text{模型 } y = W^T x + b$$